

Audit de Qualité des Données — Synthèse

A — Incohérence de la durée d'appel

Lors de l'audit, une incohérence a été détectée sur la variable `duree_appel_moyenne_sec`, absente du dataset brut. Elle a été reconstituée par calcul :

```
duree_appel_moyenne_sec = duree_appel_totale_sec / nb_appels
```

Le cas particulier `nb_appels = 0` est traité explicitement : si aucun appel n'a été émis, alors `duree_appel_totale_sec = 0` et `duree_appel_moyenne_sec = 0` par convention. Cette règle évite toute division par zéro et garantit la cohérence arithmétique du dataset. Ce point n'avait pas été suffisamment documenté dans le rapport d'audit précédent.

B — Contradiction `statut_actif` / `churn`

L'audit a révélé **76 cas contradictoires** sur 300 observations (25,3%) :

Type de contradiction	Effectif
<code>statut_actif = True</code> avec <code>churn = 1</code>	30 cas
<code>statut_actif = False</code> avec <code>churn = 0</code>	46 cas

Ce taux de 25,3% représente un bruit significatif sur la variable cible. La contradiction s'explique par la nature de `statut_actif` : il reflète le statut administratif contractuel, tandis que `churn` est construit sur un critère comportemental (récence CDR $\geq 90j$, standard INTT RGS-90). Les deux notions sont conceptuellement distinctes et ne doivent pas être synchronisées.

Décision retenue : `statut_actif` est exclu de la matrice X en tant que variable administrative non observable en temps réel. Un tableau de justification a été dressé pour documenter cette décision.

C — Stratégie de traitement des valeurs manquantes (NaN)

Plusieurs colonnes présentent des valeurs manquantes : `facture_moyenne_mensuelle`, `satisfaction_client`, `data_totale_mb`, `nb_reclamations`, `score_frustration`, `ratio_data_voix`, `ratio_sms_appels`, `tendance_data_pct`.

Deux stratégies ont été évaluées :

Option 1 — Imputation par valeur sentinelle (-1 ou "Inconnu") : rejetée. Une valeur à -1 peut induire des splits artificiels dans les arbres de décision (`data_totale_mb < 0`), créant une feature non représentative. L'encodage "Inconnu" nécessite un encodage supplémentaire sans apport garanti.

Option 2 — Conservation des NaN avec ajout de flags binaires : retenue. L'analyse a démontré que les clients présentant des NaN affichent un taux de churn significativement différent de la moyenne — le NaN porte donc une information comportementale que toute valeur imputée effacerait. Trois flags sentinelles ont été ajoutés à la matrice X : `data_manquante`, `satisfaction_manquante`, `reclamation_manquante` (0/1). XGBoost et SHAP détermineront leur importance réelle lors de la modélisation.

D — Incohérences plan tarifaire / consommation

L'audit a identifié des incohérences structurelles entre l'offre souscrite et les données de consommation enregistrées :

Cas 1 — Offre Classique avec data > 0 : 167 clients en Offre Classique présentaient une consommation data non nulle, ce qui est incompatible avec les conditions de cette offre (voix et SMS uniquement). Dans tous ces cas, les données d'appels et SMS étant cohérentes, la correction a consisté à forcer `data_totale_mb = 0`.


Cas 2 — Offre Classique avec NaN sur data : 18 clients en Offre Classique présentaient des NaN sur `data_totale_mb`. Par règle métier, leur consommation data étant structurellement nulle, ces NaN ont été remplacés par 0.

E — Vérification des doublons

L'unicité des identifiants a été vérifiée : 300 `client_id` distincts pour 300 lignes — aucun doublon détecté.


Lignes touchées par les anomalies

Tableau de bord — Audit Qualité des Données
Tunisie Télécom PFE 2025



	Réf	Anomalie	Colonnes concernées	Lignes affectées (n)	Lignes affectées (%)	T
0	A	Calcul durée appel moyenne	duree_appel_moyenne_sec	42	14.0%	E fc
1	B	Contradiction statut_actif / churn	statut_actif, churn	76	25.3%	lr rr
2	C1	NaN sur data_totale_gb (hors Offre Classique)	data_totale_gb	3	1.0%	V rr ir
3	C2	NaN sur facture_moyenne_mensuelle	facture_moyenne_mensuelle	21	7.0%	V rr ir
4	C3	NaN sur satisfaction_client	satisfaction_client	18	6.0%	V rr ir
5	D1	Offre Classique avec data_totale_gb > 0	data_totale_gb, plan_tarifaire	167	55.7%	V c rr
6	D2	Offre Classique avec data_totale_gb NaN	data_totale_gb, plan_tarifaire	18	6.0%	V rr v c

Audit — Contradictions statut_actif / churn



F — Zéros structurels (élément manquant dans ton résumé)

L'audit a mis en évidence une proportion élevée de zéros non aléatoires dans les variables d'usage, déterminés par le type d'offre souscrite :

Variable	Proportion de zéros
data_moyenne_gb	70,7%
ratio_data_voix	71,7%
duree_appel_moyenne_sec	14,0%

Ces zéros ne constituent pas des valeurs manquantes mais des **zéros structurels** reflétant l'inéligibilité fonctionnelle à certains services. Leur inclusion non conditionnée dans les statistiques descriptives globales biaise les mesures de tendance centrale. Deux flags ont été ajoutés à X pour capturer cette information : `flag_offre_data` et `flag_offre_voix`.

4. Tests de Distribution et Limites du Modèle

Nous avons utilisé les tests **Kolmogorov-Smirnov (KS)** pour le numérique et **Chi-deux (χ^2)** pour le catégoriel.

Observation : avec $n = 300$, le test KS est trop sensible : il détecte des différences statistiquement significatives mais pratiquement négligeables. Il est aussi important de noter sa sensibilité aux formes de distribution : les différences résiduelles reflètent les limites de **Gaussian Copula** sur les distributions discrètes (Poisson vs Gaussienne)

Cela étant, cette analyse nous a permis de détecter certains écarts, dont certains sont corrigeables et d'autres non. Dans certains cas, dus à notre règle métier, certaines variables sont incorrigibles. C'est le cas pour `data_totale_mb` : nos corrections ont mis à zéro la donnée de 220 clients « Offre Classique », ce qui a écrasé la distribution. Le SDV avait généré des valeurs pour tout le monde, mais nous les avons effacées. La distribution est désormais bimodale (beaucoup de zéros + quelques grandes valeurs) et ne peut pas correspondre à l'original, qui avait une distribution différente. La même raison s'applique à `data_moyenne`.

Enfin, pour `recence_cdr_jours`, nous avons forcé des valeurs à 90 jours afin de corriger le churn, ce qui a créé un pic artificiel qui n'existe pas dans la distribution originale.

Pour ce qui est du reste des analyses, elles ont été réalisées dans l'analyse exploratoire.