

Définition du Périmètre Churn

Définition du Périmètre Churn

PFE · Prédiction du churn client · Tunisie Télécom — Agence de Kairouan

1. Contexte et scénarios évalués

Trois scénarios de définition du churn ont été envisagés avant de retenir la règle métier finale. Deux d'entre eux ont été écartés après analyse.

Scénario B — Churn post-payé (résiliation explicite)

Statut : écarté.

La grande majorité des clients du dataset étant en offre prépayée (82,7% contre 17,3% en offre à facture), une définition fondée sur la résiliation contractuelle explicite aurait exclu la quasi-totalité de la base clients et produit une variable cible non représentative.

Scénario C — Churn hybride (baisse de consommation data)

Statut : écarté.

48 clients sur 300 ne présentent aucune consommation data enregistrée, soit en raison de l'absence de smartphone, soit parce que l'option internet n'est pas activée sur leur abonnement. Retenir ce critère aurait exclu une partie de la clientèle de façon arbitraire et introduit un biais de sélection dans la variable cible.

Scénario A — Churn mobile prépayé par inactivité comportementale (CDR)

Statut : retenu.

Ce scénario repose sur la variable `recence_cdr_jours`, calculable pour l'ensemble des 300 clients sans exclusion. Il constitue le seul critère à la fois exhaustif, calculable directement et représentatif du comportement réel des abonnés prépayés.

2. Règle métier retenue

Un client est considéré comme churné (`churn = 1`) **si et seulement si** son dernier événement CDR — appel émis ou reçu, SMS, ou session data — date de **plus de 90 jours** avant la date d'extraction, fixée au **01/01/2025**.

2.1. Formalisation mathématique

Soit $C = \{c_1, c_2, \dots, c_n\}$ l'ensemble des $n = 300$ clients du dataset.

Pour chaque client c_i , on note r_i le nombre de jours écoulés depuis son dernier événement CDR, calculé à la date d'extraction $d_{\text{ext}} = \text{2025-01-01}$.

La variable cible binaire $y_i \in \{0, 1\}$ est définie par :

$$y_i = \begin{cases} 1 & \text{si } r_i \geq 90 \quad (\text{client churné : inactif depuis plus de 90 jours}) \\ 0 & \text{sinon} \quad (\text{client actif}) \end{cases}$$

Cette règle produit un taux de churn empirique de $\bar{y} = 27,7\%$ sur l'échantillon étudié.

2.2. Construction de `recence_cdr_jours`

`recence_cdr_jours` n'est pas une variable brute issue d'un système d'information. Elle est calculée lors de la phase d'agrégation CDR selon la logique suivante :

- Les événements CDR de chaque client sont générés avec un horodatage `date_heure` tiré aléatoirement entre la date de début d'abonnement et la date d'extraction.
- L'agrégation par client extrait ensuite la date du dernier événement via :
`date_dernier_evenement = ("date_heure", "max")`.
- La récence est alors calculée par : $r_i = (d_{\text{ext}} - d_{\text{CDR},i}^{\text{max}})$ (en jours).

La colonne `date_dernier_evenement` est ensuite supprimée, l'information étant entièrement résumée dans `recence_cdr_jours`.

La construction de cette variable est antérieure à l'application de la règle de churn, mais postérieure à la décision de retenir le critère d'inactivité comportementale. Cette démarche est méthodologiquement valide : dans un contexte opérateur réel, la récence CDR est calculable en temps réel depuis les tables de facturation, indépendamment de toute définition de churn.

Ce qui constituerait une circularité problématique, c'est d'utiliser `recence_cdr_jours` comme *feature* prédictive dans le modèle ML — ce que le

présent travail exclut explicitement (cf. section 4).

3. Justification du seuil de 90 jours

3.1. Analyse de sensibilité

Pour démontrer que le choix de 90 jours n’est pas arbitraire, une analyse de sensibilité a été conduite en faisant varier le seuil d’inactivité de 30 à 120 jours. Le tableau ci-dessous présente le taux de churn obtenu pour chaque valeur testée.

Seuil (jours)	Taux de churn (%)
30	55,7
60	37,0
90	27,7
120	22,3

[Insérer ici le graphique de sensibilité]

La courbe décroît de façon monotone à mesure que le seuil augmente. On observe une inflexion plus marquée entre 60 et 90 jours, au-delà de laquelle la pente s’atténue sensiblement, suggérant que 90 jours constitue un point de stabilisation naturel. Les seuils inférieurs (30–45 jours) produisent un taux artificiellement élevé, incompatible avec un marché où le rechargement prépayé peut être irrégulier sans pour autant signifier un départ définitif.

3.2. Ancrage réglementaire tunisien

Le seuil retenu est directement aligné sur la définition réglementaire officielle en vigueur en Tunisie.

L’Instance Nationale des Télécommunications (INT) définit un abonnement mobile actif — sous l’appellation **RGS-90** — comme toute carte SIM ayant enregistré au moins un événement CDR au cours des trois derniers mois, soit 90 jours (INT, Observatoire des Télécommunications, 2025). La règle métier appliquée dans ce travail constitue donc le standard réglementaire tunisien.

3.3. Pratiques opérateurs africains

Cette approche est également cohérente avec les pratiques observées chez les opérateurs de la région.

La GSMA documente que la majorité des opérateurs mobiles en Afrique du Nord et en Afrique australe considèrent un client comme inactif après 60 à 90 jours sans activité CDR. À titre d'exemple concret, MTN Afrique du Sud désactive une SIM lorsqu'aucun événement facturable n'a été généré durant les 90 jours suivant l'activation (GSMA Mobile for Development).

4. Data leakage et liste des features prédictives

`recence_cdr_jours` servant à construire la variable cible `churn`, elle est **exclue** du jeu de *features* prédictives. L'inclure constituerait une fuite de données (*data leakage*) rendant le modèle trivial et non généralisable.

Les variables prédictives envisagées sont regroupées en cinq familles :

- **Profil contractuel** — `type_abonnement`, `plan_tarifaire`, `tenure_mois`, `facture_moyenne_mensuelle`, `moyen_paiement` : ces variables caractérisent l'engagement contractuel du client et son niveau de dépense.
- **Usage télécom (CDR agrégé)** — `nb_appels`, `duree_appel_totale_sec`, `duree_appel_moyenne_sec`, `sms_total`, `data_totale_mb`, `nb_evenements_data_cdr` : l'intensité d'usage est un signal direct du lien du client au réseau.
- **Tendance de consommation** — `data_mois_M`, `data_mois_M1`, `tendance_data` : la variation de consommation entre le dernier mois et le mois précédent capte un signal de désengagement progressif.
- **Engagement digital** — `nb_sessions`, `duree_session_moyenne_sec`, `recence_session_jours`, `taux_cookies` : l'activité sur l'application MyTT reflète l'attachement au service au-delà de l'usage voix/SMS.
- **Qualité de service et satisfaction** — `zone_reseau_principale`, `qualite_signal_dominante`, `score_qualite_zone`, `satisfaction_client`, `nb_reclamations`, `score_frustration` : la qualité perçue du réseau et le niveau de frustration sont des prédicteurs reconnus du churn dans la littérature télécom.

Cette liste est préliminaire et sera affinée lors de la phase de sélection de variables (importance des features, corrélations), après gestion des valeurs manquantes.

5. Distribution de la variable cible et déséquilibre des classes

[Insérer ici le graphique en barres churné / non-churné]

Avec 27,7% de churners, le dataset présente un déséquilibre modéré des classes (1 churning pour ~2,6 fidèles). Ce déséquilibre a trois implications directes sur la modélisation :

- **Métriques d'évaluation.** L'accuracy seule est trompeuse : un classifieur naïf prédisant systématiquement « non-churné » obtiendrait déjà ~72% d'accuracy sans rien apprendre. Les métriques à privilégier sont le F1-score (classe minoritaire), l'AUC-ROC et la courbe Precision-Recall.
- **Stratégies de rééquilibrage.** Plusieurs techniques seront envisagées lors de la phase de modélisation : suréchantillonnage de la classe minoritaire (SMOTE), pondération des classes (`class_weight='balanced'` dans scikit-learn, `scale_pos_weight` dans XGBoost), et sous-échantillonnage. Chaque stratégie fera l'objet d'une description et d'une comparaison dans le rapport.
- **Seuil de décision.** Le seuil de probabilité par défaut (0,5) pourra être ajusté pour optimiser le rappel sur la classe churners, selon l'arbitrage entre le coût d'une action de rétention et le coût d'un faux négatif (churner non détecté).

6. Benchmark et cohérence du taux obtenu

Le taux de churn obtenu (27,7%) se situe dans la fourchette observée pour les marchés mobiles émergents. Bain & Company estime que le churn mobile dans ces marchés peut varier de 20% à 50% selon les contextes concurrentiels et réglementaires (SubscriptionFlow, 2022).

Ce résultat est cohérent avec un marché à dominante prépayée où le changement de SIM est aisé et la fidélité contractuelle absente. Il convient toutefois de noter que, le dataset étant simulé, ce taux reflète la règle métier appliquée et non une mesure terrain réelle.