

Partie 2 — Audit de Qualité : Identification des Anomalies

Avant toute phase d'enrichissement ou de modélisation, un audit a été conduit sur le dataset brut afin d'identifier les incohérences susceptibles de compromettre la qualité du modèle.

2.1 — Incohérences de durée

La vérification de la contrainte `duree_appel_totale_sec = nb_appels × duree_appel_moyenne_sec` a révélé une anomalie systématique affectant 281 lignes sur 300. La cause racine a été identifiée dans le notebook de génération : `duree_appel_moyenne_sec` a été calculée en divisant la durée totale par `nb_evenements_total` (appels + SMS + sessions data) au lieu de `nb_appels` uniquement, produisant une durée moyenne systématiquement sous-estimée. La correction consiste à recalculer `duree_appel_moyenne_sec = duree_appel_totale_sec / nb_appels`.

2.2 — Contradictions entre `statut_actif` et `churn`

L'analyse croisée a mis en évidence deux types de contradictions : 30 clients présentent `statut_actif = True` avec `churn = 1`, et 46 clients présentent `statut_actif = False` avec `churn = 0`. Ainsi donc nous nous exposons à un problème probable de bruit lors de la construction du modèle. Que faire alors dans ce cas ?

Synchroniser `statut_actif` sur `churn` nous paraissait être la bonne solution mais cela créerait une redondance de sens compte tenu du fait que déjà la recence_CDR encadre le churn donc nous nous permettons toutefois de soumettre une observation à ce sujet : cette synchronisation supprimerait la divergence entre le statut administratif du SI et le comportement CDR réel, ce qui efface le profil du *Silent Churner* — un client dont le contrat est toujours ouvert mais dont la dernière activité remonte à plus de 90 jours. Cette divergence pourrait constituer un signal exploitable. Par contre nous proposons en alternative de **conserver `statut_actif` dans le dataset brut** comme métadonnée administrative, tout en **l'excluant de la matrice X** lors de l'entraînement.

2.3 — Données manquantes déguisées

Le dataset intègre intentionnellement des valeurs manquantes simulant les imperfections d'un SI réel. L'audit a porté sur trois colonnes : `satisfaction_client` (18 NaN), `nb_reclamations` (48 NaN) et `data_totale_mb` (21 NaN), chacune intégralement signalée par un flag binaire dédié.

Ces absences ne sont pas aléatoires — elles sont porteuses d'information métier. Le taux de NaN sur `satisfaction_client` atteint 16,2 % chez les clients inactifs contre 1 % chez les actifs (mécanisme MAR), et les lignes avec données manquantes affichent un taux de churn supérieur à la moyenne (33–39 % vs 27,7 %). La distinction entre `nb_reclamations = NaN` (client n'ayant jamais contacté le support) et `nb_reclamations = 0` (client ayant contacté le support sans réclamation) illustre également la valeur sémantique de ces absences.

L'audit a par ailleurs mis en évidence certaines incohérences dont celles entre plan tarifaire et consommation data par exemple : 167 clients souscrits à l'Offre Classique — qui n'inclut pas l'accès internet — présentent une consommation data supérieure à zéro. À l'inverse, 3 clients disposant d'un Forfait Mobile avec internet affichent `data_totale_mb = 0` malgré des sessions et des événements CDR enregistrés. Ces incohérences suggèrent une désynchronisation entre la table clients et la table usage lors de l'agrégation, ce qui tout naturellement fera l'œuvre d'une inspection puis de modifications.

La stratégie de traitement retenue est de **remplacer tous les NaN par la modalité "Inconnu"** pour les variables catégorielles, et par la **valeur sentinelle -1** pour `data_totale_mb`. Les trois colonnes indicatrices devenant redondantes, elles seront supprimées de la matrice X. Un encodage adapté de la modalité "Inconnu" sera appliqué lors de la phase de prétraitement.