

RAPPORT DE SYNTHÈSE

Génération de Données Synthétiques

Partie 4 — Plateforme Intelligente de Prédiction du Churn

Tunisie Télécom — Agence Kairouan

Projet de Fin d'Études — Licence Business Computing

Date : 01 April 2026

Fiche synthétique du dataset	
Dataset analysé	dataset_sdv_final.csv (300 lignes, 38 colonnes)
Méthode de génération	SDV — GaussianCopulaSynthesizer
Taux de churn observé	27.7% (83 clients churné sur 300)
Biais métier injectés	3 (data faible, frustration, réseau rural)
Format d'export	CSV enrichi (ML-ready)

1. Contexte et Objectifs

Ce rapport présente les résultats de la Partie 4 du projet de fin d'études portant sur la conception d'une plateforme intelligente de prédiction du churn, de segmentation client et d'aide à la décision marketing pour l'agence de Kairouan de Tunisie Télécom. Cette partie porte spécifiquement sur la génération de données synthétiques réalistes servant de base à l'entraînement du modèle de prédiction.

1.1 Questions métier auxquelles ce rapport répond

- Q1 — Quel est le profil statistique des clients de l'agence Kairouan ?
- Q2 — Quels segments présentent le taux de churn le plus élevé ?
- Q3 — Quels sont les indicateurs d'usage qui distinguent le mieux les clients churné des actifs ?
- Q4 — La génération SDV reproduit-elle fidèlement la structure statistique du dataset réel ?
- Q5 — Les biais métier injectés renforcent-ils la cohérence des corrélations churn/usage ?

1.2 Pipeline de génération

Le dataset synthétique final résulte d'un pipeline en quatre étapes : (1) génération manuelle via le script `generator.py` avec règles métier télécom, (2) apprentissage de la structure statistique par SDV (`GaussianCopulaSynthesizer`), (3) correction post-génération sur les colonnes à distribution asymétrique, (4) injection de biais métier forçant trois corrélations réalistes.

2. Statistiques Descriptives du Dataset Enrichi

2.1 Vue d'ensemble (Q1)

Indicateur	Valeur	Interprétation
Nombre de clients	300	Taille suffisante pour l'entraînement ML
Nombre de features	38	Variables comportementales, usage, localisation
Taux de churn global	27.7%	Déséquilibre modéré — SMOTE recommandé en ML
Clients actifs	217 (72.3%)	Majorité de clients engagés
Clients churné	83 (27.7%)	Cible de prédiction du modèle
Tenure moyen	34.3 mois	Base client établie (~ 3 ans d'ancienneté)
Facture moyenne	29.1 DT/mois	Profil économique dominant (offre classique)
Satisfaction moyenne	2.45 / 5	Niveau de satisfaction globalement faible

2.2 Répartition par type d'abonnement et plan tarifaire

Type d'abonnement	Effectif	Part	Taux de churn
Offre Prépayée	248	82.7%	0.258 (25.8%)
Offre à Facture	52	17.3%	0.365 (36.5%)

Plan tarifaire	Effectif	Part	Taux de churn
Offre Classique	209	69.7%	33.0%
Forfait Mobile (Mixte)	64	21.3%	20.3%
Forfait Illimité	27	9.0%	3.7%

Réponse Q1 — Le portefeuille client est dominé par les abonnés prépayés (82.7%) sur Offre Classique (69.7%). La base est constituée de clients à faible engagement digital, ce qui explique le taux de churn significatif de 27.7%.

2.3 Répartition géographique

Zone réseau	Effectif	Part	Taux de churn
URBAIN	178	59.3%	27.5%
SUBURBAIN	88	29.3%	27.3%
RURAL	34	11.3%	29.4%

Qualité signal	Effectif	Part	Taux de churn
Excellent	131	43.7%	29.8%

Bon	148	49.3%	27.7%
Faible	21	7.0%	14.3%

3. Analyse des Segments à Risque (Q2)

Cette section identifie les profils clients présentant les taux de churn les plus élevés, permettant de cibler les actions marketing préventives.

3.1 Classement des segments par taux de churn

Segment	Taux de churn	Niveau de risque
Offre à Facture	36.5%	ÉLEVÉ
Offre Classique	33.0%	ÉLEVÉ
Zone RURAL	29.4%	MODÉRÉ
Signal Excellent	29.8%	MODÉRÉ
Prélèvement bancaire	31.0%	MODÉRÉ
Forfait Mobile (Mixte)	20.3%	FAIBLE
Forfait Illimité	3.7%	TRÈS FAIBLE

Réponse Q2 — Les deux segments à risque prioritaires sont : (1) les clients Offre à Facture (36.5% de churn malgré seulement 17.3% du portefeuille) et (2) les clients Offre Classique sans accès data (33.0%). À l'inverse, le Forfait Illimité présente un taux de churn quasi nul (3.7%), confirmant que l'engagement digital est un facteur protecteur majeur.

4. Indicateurs Discriminants : Churné vs Actifs (Q3)

La comparaison des moyennes entre clients churné (churn=1) et actifs (churn=0) permet d'identifier les features les plus discriminantes pour le modèle ML.

Feature	Actifs (moy.)	Churné (moy.)	Écart	Signal
Consommation data (MB)	64.6	7.9	-87.8%	Très fort
Nombre d'appels	6.7	3.7	-44.8%	Fort
SMS total	5.2	2.7	-48.1%	Fort
Récence CDR (jours)	55.0	208.7	+279.5%	Très fort
Satisfaction client	2.7	1.9	-29.6%	Modéré
Nb. réclamations	2.6	4.1	+57.7%	Modéré
Score frustration	11.1	18.6	+67.6%	Modéré
Tenure (mois)	32.1	40.1	+24.9%	Faible
Facture mensuelle (DT)	26.0	37.0	+42.3%	Modéré

Réponse Q3 — Les deux indicateurs les plus discriminants sont : (1) la récence CDR : les clients churné n'ont aucune activité depuis 208 jours en moyenne contre 55 jours pour les actifs (+280%), ce qui justifie la règle métier recence >= 90j ; (2) la consommation data : les churné consomment 8x moins de data (7.9 MB vs 64.6 MB), signal d'un désengagement digital précédant le départ.

5. Validation de la Fidélité SDV (Q4)

La qualité du dataset synthétique généré par SDV est évaluée en comparant les distributions marginales et les métriques clés entre le dataset original et le dataset synthétique. Le critère de qualité retenu est un écart relatif inférieur à 20% sur les indicateurs principaux.

Métrique	Original	Synthétique	Écart	Statut
Taux de churn	27.3%	26.7%	2%	✓
Data totale (MB)	49.4	49.4	0%	✓
Récence CDR (jours)	109.1	108.2	1%	✓
Nombre d'appels	5.9	5.9	0%	✓
Satisfaction client	2.5	2.6	5%	✓
Nb. réclamations	3.1	2.8	11%	✓
Plan Offre Classique	70.0%	73.0%	4%	✓
Plan Mixte	21.0%	20.0%	5%	✓
Plan Illimité	9.0%	7.0%	22%	■

Réponse Q4 — 8 métriques sur 9 présentent un écart inférieur à 15%, validant la fidélité statistique du dataset SDV. Le seul écart significatif concerne le Forfait Illimité (22%), attribuable à la faible représentation de ce segment (27 clients) qui rend l'estimation SDV moins stable. Des corrections post-génération (facteurs de recalibration multiplicatifs) ont été appliquées sur data_totale_mb et nb_appels.

6. Biais Métier Injectés (Q5)

SDV capture les corrélations statistiques globales mais ne garantit pas les règles métier propres au secteur télécom. Trois biais ont été injectés manuellement pour renforcer la cohérence du dataset vis-à-vis de la réalité opérationnelle de Tunisie Télécom.

Biais	Signal	Condition	Action	Justification métier
Biais 1	Data faible	data_totale_mb < 15e percent	30% des cas → churn=1	Un client qui n'utilise plus sa data mobile est un signal fort
Biais 2	Frustration élevée	score_frustration > 80e percent	25% des cas → churn=1	Réclamations répétées + insatisfaction = combinaison pré
Biais 3	Réseau rural dégradé	RURAL + signal Faible	40% des cas → churn=1	Mauvaise couverture = motif de résiliation déclaré le plus

Taux de churn avant injection	26.7%
Taux de churn après injection	31.3%
Clients basculés en churn	14 (+4.6 points)

Réponse Q5 — Les biais métier ont augmenté le taux de churn de 4.6 points. L'écart par rapport à la cible (27%) s'explique par la faible population des segments à risque dans un dataset de 300 lignes : chaque client basculé représente 0.33% du taux total. À l'échelle réelle (plusieurs milliers de clients), cet effet serait proportionnellement plus fin et plus précis.

7. Conclusions et Recommandations

7.1 Synthèse des résultats

- Le dataset synthétique de 300 clients est statistiquement fidèle au dataset réel (8 métriques sur 9 dans la tolérance de 20%).
- Le taux de churn de 27.7% reflète un déséquilibre modéré, justifiant l'application de SMOTE ou de class_weight lors de l'entraînement ML.
- Les features les plus discriminantes identifiées sont : recence_cdr_jours, data_totale_mb, nb_appels et score_frustration — à prioriser dans la sélection de features.
- Les clients Offre à Facture (36.5%) et Offre Classique (33.0%) constituent les segments prioritaires pour les campagnes de rétention.
- Le Forfait Illimité est un facteur protecteur contre le churn (3.7%) — sa promotion auprès des segments à risque constitue un levier marketing efficace.

7.2 Recommandations pour la suite du projet

Phase ML	Utiliser class_weight='balanced' ou SMOTE pour corriger le déséquilibre 72/28
Features	Prioriser recence_cdr_jours, data_totale_mb, score_frustration en feature selection
Segmentation	Croiser les segments churn avec la segmentation K-Means pour affiner les profils
Marketing	Cibler en priorité les clients Offre Classique avec data_manquante=1 (Silent Churners)
Données réelles	Appliquer le modèle entraîné sur le dataset réel TT pour validation terrain

Rapport généré le 01/04/2026 — Projet de Fin d'Études, Licence Business Computing — Faculté des Sciences Économiques et de Gestion de Nabeul (FSEGN)